



FISH STATS

Guilhem C., Abel G.



Fish Stats

Statistiques descriptives

On se souvient de la différence entre **quantitatif** et **qualitatif**. Certaines données doivent être regroupées en catégories pour avoir un sens (ex : taille). On utilise alors les

classes : $A = \{[a_{i-1}, a_i]\}_{i=1}^k$.

Quelques fonctions de base : - **Moyenne empirique** : $\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$. - **Valeurs**

extrêmes : $x_{(1)} = \min_{i \in [1, n]} x_i$ et $x_{(n)} = \max_{i \in [1, n]} x_i$ (ordres statistiques). - **Médiane**

empirique : - Si n est impair, $\tilde{x}_n = x_{(\frac{n+1}{2})}$. - Si n est pair, $\tilde{x}_n = \frac{1}{2}(x_{(n/2)} + x_{(n/2)+1})$. -

Quantiles empiriques.

Lorsque nous analysons des données ou leurs représentations, il est important de se poser quelques questions :

- **Introspection** : suis-je objectif ? Quels biais peuvent affecter mon interprétation ?
- **Perspective** : ai-je considéré un contexte plus large ? Quelles sont les interprétations possibles et les contre-interprétations ?
- **Qualité de la présentation** : la visualisation et les indicateurs sont-ils pertinents ? Quelles informations manquent (taille de l'échantillon, méthode de collecte...) ?

- **Source** : qui publie les données ? La source est-elle fiable ? Comment l'étude a-t-elle été financée ?

Estimation statistique

Une variable aléatoire X est définie sur un univers Ω . Si l'image de Ω par X est finie ou dénombrable on dit que X est **discrète**, sinon elle est **continue**.

Deux fonctions importantes :

1. **Fonction de répartition (CDF)** : $F_X(x) = \mathbb{P}(X \leq x) = \sum_{\{\omega: X(\omega) \leq x\}} \mathbb{P}(\omega)$.
2. **Fonction de masse** (pour les variables **discrètes**) :
 $f_X(x) = \mathbb{P}(X = x) = \sum_{\{\omega: X(\omega)=x\}} \mathbb{P}(\omega)$.
3. Pour les variables continues on utilise une **densité** f_X telle que
 $F_X(x) = \int_{-\infty}^x f_X(t) dt$.

À faire : espérance, variance, théorème de transfert

Variables aléatoires usuelles discrètes

Loi uniforme

Une variable aléatoire X suit la loi uniforme ($X \sim \mathcal{U}(n)$) sur $\{1, \dots, n\}$ si
 $\mathbb{P}(X = k) = 1/n$ pour $k = 1, \dots, n$.

Alors $\mathbb{E}(X) = \frac{n+1}{2}$ et $\mathbb{V}(X) = \frac{n^2-1}{12}$.

Loi de Bernoulli

$X \sim \mathcal{B}[1, p]$ si $\mathbb{P}(X = 1) = p$ et $\mathbb{P}(X = 0) = 1 - p$.

Alors $\mathbb{E}(X) = p$ et $\mathbb{V}(X) = p(1 - p)$.

Loi binomiale

$X \sim \mathcal{B}(n, p)$ si $\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$ pour $k = 0, \dots, n$.

Alors $\mathbb{E}(X) = np$ et $\mathbb{V}(X) = np(1-p)$.

Remarque : $\mathcal{B}(n, p)$ est la somme de n variables indépendantes $\mathcal{B}(1, p)$.

Loi de Poisson

$X \sim \mathcal{P}(\lambda)$ si $\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}$ pour $k \in \mathbb{N}$.

Alors $\mathbb{E}(X) = \lambda$ et $\mathbb{V}(X) = \lambda$.

Cette loi modélise des événements rares et approximations de comptages indépendants.

Agrégation des variables aléatoires

Soit $X_1, \dots, X_n$ iid d'espérance μ et de variance σ^2 . La moyenne empirique est $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$. On a $\mathbb{E}(\bar{X}_n) = \mu$ et $\mathbb{V}(\bar{X}_n) = \sigma^2/n$.

Loi des grands nombres : - Version faible : $\forall \varepsilon > 0, \mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) \rightarrow 0$ quand $n \rightarrow \infty$. - Version forte : $\mathbb{P}(\lim_{n \rightarrow \infty} \bar{X}_n = \mu) = 1$.

Théorème central limite (TCL) :

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1).$$

Propriétés : - Si $X_1, \dots, X_n$ sont indépendantes,

$\mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n) = \prod_{i=1}^n \mathbb{P}(X_i \leq x_i)$. - Si elles sont identiquement distribuées, $\forall i, j, \mathbb{P}(X_i \leq x) = \mathbb{P}(X_j \leq x)$.

Notion de statistique

Une statistique est une fonction des données $\vec{x} \mapsto t(\vec{x})$. Exemple : la moyenne empirique $\hat{\mu}_n = \frac{1}{n} \sum_{i=1}^n x_i$ ou le maximum $\max_i x_i$.

Un estimateur T_n d'un paramètre θ est une statistique dont la valeur estimée vise θ .

Qualité d'un estimateur

Le biais est $b(T_n, \theta) = \mathbb{E}(T_n) - \theta$. T_n est sans biais si $b(T_n, \theta) = 0$.

La variance $\mathbb{V}(T_n)$ mesure la dispersion autour de $\mathbb{E}(T_n)$.

L'erreur quadratique moyenne (MSE) :

$$\mathcal{MSE}(T_n) = \mathbb{E}[(T_n - \theta)^2] = \mathbb{V}(T_n) + b(T_n, \theta)^2.$$

Loi normale

Rappel : $X \sim \mathcal{N}(\mu, \sigma^2)$ a pour densité

$$f(x \mid \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$

Propriétés pratiques : 1. $\mathbb{P}(X \in]\mu - \sigma, \mu + \sigma[) \approx 0.68$. 2.

$\mathbb{P}(X \in]\mu - 2\sigma, \mu + 2\sigma[) \approx 0.95$. 3. $\mathbb{P}(X \in]\mu - 3\sigma, \mu + 3\sigma[) \approx 0.997$.

Standardisation : $Z = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1)$. Notons $\Phi(t) = \mathbb{P}(Z \leq t)$ la CDF de la loi

normale centrée réduite. - Symétrie : $\Phi(-t) = 1 - \Phi(t)$. - Valeur absolue :

$\mathbb{P}(|Z| < t) = 2\Phi(t) - 1$.

Intervalles de confiance

Pour un niveau de confiance $1 - \alpha$, soit $z_{1-\alpha/2}$ le quantile de $\mathcal{N}(0, 1)$. Ex :

$z_{0.975} \approx 1.96$, $z_{0.995} \approx 2.58$.

- Si σ connu :

$$I_{1-\alpha} = \left[\bar{X}_n - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X}_n + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right].$$

- Si σ inconnu : on estime par

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

et on utilise la loi de Student :

$$I_{1-\alpha} = \left[\bar{X}_n - t_{n-1, 1-\alpha/2} \frac{S}{\sqrt{n}}, \bar{X}_n + t_{n-1, 1-\alpha/2} \frac{S}{\sqrt{n}} \right],$$

où $t_{n-1, 1-\alpha/2}$ est le quantile de Student à $n - 1$ degrés de liberté.

- Pour une proportion (Binomiale), avec $\hat{p}$ la proportion observée :

$$I_{1-\alpha, \hat{p}} = \left[\hat{p} - z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \hat{p} + z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right].$$

On peut utiliser $1/4$ comme borne supérieure conservative pour $\hat{p}(1-\hat{p})$.

Maximisation de vraisemblance

La **vraisemblance** est la probabilité qu'un événement arrive plus ou moins souvent.



RAPPEL

1. Pour une v.a. discrète, $f(x|\theta) = \mathbb{P}(X = x|\theta)$
2. Pour une v.a. continue, $\forall a, b \in X(\Omega), \mathbb{P}(X \in [a, b]|\theta) = \int_a^b f(x|\theta)dx$

En pratique, nous connaissons l'expression de $f(x|\theta)$, et on va étudier les variations de f afin de déterminer son maximum, par rapport à θ et en fonction de x . On utilise la **fonction de vraisemblance** qui est le produit des $\mathcal{L}(\theta) = f(x|\theta)$ (on cherche la probabilité d'avoir toutes ses observations **en même temps**).

On note $\hat{\theta}$ **l'estimateur maximal de vraisemblance (EMV)** Il correspond à la dérivée de $\mathcal{L}$.

On effectue ensuite une **log vraisemblance** pour transformer les produits en sommes et obtenir. Enfin, on trouve les racines en 0 et on conclut.



MÉTHODOLOGIE : PROUVER QU'UNE STATISTIQUE EST EXHAUSTIVE

Pour trouver ou prouver qu'une statistique $T(X)$ est exhaustive pour un paramètre θ à l'aide du théorème de factorisation :

1. **Écrire la fonction de vraisemblance** de l'échantillon complet :

$$\mathcal{L}(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i | \theta)$$

1. **Développer et regrouper les termes** : Utilise les propriétés des puissances et des exponentielles pour rassembler tout ce qui dépend de θ .
2. **Forcer la factorisation** sous la forme $\mathcal{L} = g(T(x), \theta) \times h(x)$:
3. $g(T(x), \theta)$: Doit contenir **tous** les θ , associés à une fonction des données (c'est ta statistique $T(x)$).
4. $h(x)$: Doit contenir **uniquement** des données ou des constantes, et **aucun** θ . (Note : $h(x)$ peut tout à fait être égal à 1).
5. **Conclure** : "D'après le théorème de factorisation de Fisher-Neyman, $T(X)$ est une statistique exhaustive pour θ ."