ESTIMATION STATISTIQUE

Estimation Statistique

DANGER

Cette fiche est encore en très grosse construction.

Promis, je ratrape mon retard !

Objets mathématiques utilisés en statistique

DÉFINITION

Un vecteur de données $\vec{x} = (x_1, \ldots, x_n)$ est de taille n (la taille de l'échantillon). Ces données sont réalisées par des variables aléatoires $\vec{X} = (X_1, \ldots, X_n)$.

X est définie sur un univers Ω. Si Ω est fini, alors on dit que X est une variable aléatoire **discrète**. Dans le cas contraire, X est **continue**.

On note également ω les éléments de l'univers (appelés *issues*). Elles sont **aléatoires**, tout comme X.

DÉFINITION

Une **fonction de répartition** F_X d'une variable aléatoire X est définie tel que :

$$\forall x \in X(\Omega), F_X(x) = \mathbb{P}(X \leq x) = \sum_{\{\omega : X(\omega) \leq x)\}} \mathbb{P}(\omega)$$

Une **fonction de masse** f_X d'une variable aléatoire X est définie tel que :

$$\forall x \in X(\Omega), f_X(x) = \mathbb{P}(X = x) = \mathbb{P}(\omega | X(\omega) = x)$$

On peut écrire la fonction de répartition F_X à partir de la fonction de masse f_X : $F_X(x) = \sum_{g \in X(\omega), y \leq x} f_X(y)$.

À faire : - Def espérance - Def Variance (plusieurs) - théorème de transfert

---

Variables Aléatoires Usuelles Discrètes

Loi uniforme

Une variable aléatoire X suis une loi de uniforme ($X \hookrightarrow \mathcal{U}$) si $\mathbb{P}(X = k) = 1/n | k \in [\![1, n]\!]$

Alors, $\mathbb{E}(X) = \frac{n+1}{2}$ et $\mathbb{V} = \frac{n^2-1}{12}$. On a également $X(\Omega) = [\![1, n]\!]$

Loi de Bernoulli

Une variable aléatoire X suis une loi de Bernoulli ($X \hookrightarrow \mathcal{B}]\nabla(p)$) si $\mathbb{P}(X = 0) = 1 - p$ et $\mathbb{P}(X = 1) = p$

Alors, $\mathbb{E}(X) = p$ et $\mathbb{V} = p(1 - p)$

Loi Binomiale

Une variable aléatoire X suis une loi Binomiale ($X \hookrightarrow \mathcal{B}(n, p)$) si $\forall k \in \mathbb{N}, \mathbb{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$

Alors, $\mathbb{E}(X) = np$ et $\mathbb{V} = np(1 - p)$

> 💡 **REMARQUE**
>
> Une loi binomiale $B(n, p)$ correspond à la répétition de n loi de Bernoulli $Ber(p)$.

Loi de Poisson

Une variable aléatoire X suis une loi de Poisson ($X \hookrightarrow \mathcal{P}(\lambda)$) si
$\forall k \in \mathbb{N}, \mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}$

Alors, $\mathbb{E}(X) = \lambda$ et $\mathbb{V} = \lambda$

Cette loi modélise des événements indépendants qui ont lieu peu souvent.

Variables Aléatoires Usuelles Continues

Loi Uniforme Continue

Une variable aléatoire X suis une loi de uniforme ($X \hookrightarrow \mathcal{U}([\![a, b]\!])$) si

Loi Géométrique

Une variable aléatoire X suis une loi Géométrique ($X \hookrightarrow \mathcal{P}(\lambda)$) si
$X = min\{Y_k = 1 | k \in \mathbb{N}^*\}$. Alors, $\mathbb{P}(X = k) = (1 - p)^{k-1} p$

Alors, $\mathbb{E}(X) = \frac{1}{p}$ et $\mathbb{V} = \frac{1-p}{p^2}$

Cette loi modélise des la répétition d'une épreuve de Bernoulli jusqu'à son premier succès.

Loi Normale

Une variable aléatoire X suis une loi Géométrique ($X \hookrightarrow \mathcal{N}(\mu, \sigma^2)$) si
$\forall x \in \mathbb{R}, \mathbb{P}(X = x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$

Alors, $\mathbb{E}(X) = \frac{1}{p}$ et $\mathbb{V} = \frac{1-p}{p^2}$

Agrégation des variables aléatoires

Soit $X_1, \ldots, X_n$ v.a. **iid** d'espérance μ et de variance σ^2. On note $\tilde{X}_n = \frac{1}{n} \sum X_i$ l'agrégation des variables aléatoires. Son espérance vaut μ et sa variance $\frac{\sigma^2}{n}$.

THÉORÈME : LOI DES GRAND NOMBRES

- *Version faible :* $\forall \varepsilon > 0, \mathbb{P}(|\tilde{X}_n - \mu| > 0) \xrightarrow[n \to +\infty]{} 0$
- *Version forte :* $\mathbb{P}(\tilde{X}_n \xrightarrow[n \to +\infty]{} \mu) = 0$

Avec une variable aléatoire agrégée (qu'on aime noter $\tilde{X}_n$), on peut appliquer le **théorème central limite** :

THÉORÈME : CENTRAL LIMTE (TCL)

$$\frac{\tilde{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \xrightarrow[n \to +\infty]{} = \mathcal{N}(0, 1)$$

Il est principalement utilisé pour justifier la construction d'Intervalles de confiance.

EXAMPLE

L'agrégation de lancés de pièces tend vers la quantité $p = \frac{1}{2}$, donc si on enlève l'espérance μ tend vers 0 (loi normal).

Propriétés sur les variables aléatoires

En statistiques, on travaille avec des variables aléatoires mutuellement indépendantes (1) et identiquement distribués (2). On abrège en **iid*.

1. $\forall x_1, \ldots, x_n, \mathbb{P}(X_1 \leq x_1 \cap \cdots \cap X_n \leq x_n) = \prod_{i=1}^{n} \mathbb{P}(X_i \leq x_i)$
2. $\forall x \in \mathbb{R}, \forall (i, j) \in [\![1, n]\!]^2 \mathbb{P}(X_i \leq x_i) = (X_j \leq x_j)$

Avec la notion de fonction de masse/densité :

$\forall x \in \mathbb{R}, f_{x_1}(x) = f_{x_2}(x) = \cdots = f_{x_n}(x)$

PROPRIÉTÉS : POUR TOUT TYPE DE VARIABLES ALÉATOIRES

- $\forall a, b \in \mathbb{R}, \mathbb{E}(aX + b) = a\mathbb{E}(X) + b$
- $\mathbb{E}(X_1, \ldots, X_n) = \sum_{i=1}^{n} \mathbb{E}(X_i)$
- $\forall a, b \in \mathbb{R}, \mathbb{V}(aX + b) = a^2\mathbb{V}(X)$
- $\mathbb{V}(X_1, \ldots, X_n) = \sum_{i=1}^{n} \mathbb{V}(X_i)$

Dépendance par rapport à des paramètres

Toute loi dépend d'un ou plusieurs paramètre(s) (que nous noterons θ).

EXEMPLE : $\mathcal{B}]\nabla(p) \longrightarrow \theta = p$; $\mathcal{B}(n, p) \longrightarrow \theta = (n, p)$.

On note $f_x(x|\theta)$ la fonction de densité/masse sachant θ. Une même loi avec des paramétrisations différentes donne des résultats différents.

Notion de statistique

DÉFINITION

Une **statistique** est une fonction quelconque des données $\vec{x}$: $t(\vec{x})$.

Le but des statistiques est de faire **parler les données**. Un exemple de statistique serait la **moyenne empirique** $\widehat{x}_n = \sum x_i$ ou le maximum $\max_{i \in [\![1,n]\!]} x_i$.

En mathématiques, on aura besoin d'une loi de probabilité et/ou d'une variable aléatoire pour remplacer les données.

📚 **DÉFINITION**

Un **estimateur** T_n d'une grandeur θ est une statistique à valeur dans Θ des θ possibles.

Elle prend en argument l'ensemble des variables aléatoires considérées $\vec{X}$.

La plupart du temps, les estimateurs nous serrons donnés.

Qualité d'un estimateur

On peut quantifier la qualité d'un estimateur avec les outils suivants :

Biais

On le note $\mathcal{B}(T_n, \theta)$, et il mesure **la précision de T_n par rapport à θ**. T_n est dit **sans biais** si $\mathbb{E}(T_n) = \theta$.

Variance d'un estimateur

$\mathbb{V}(T_n)$ quantifie les fluctuations de T_n autour de son espérance $\mathbb{E}(T_n)$.

Consistance

Si $T_n \xrightarrow[n \to +\infty]{} \theta$, alors T_n est **consistant** pour θ.

Erreur Quadratique

📚 **DÉFINITION**

L'erreur quadratique moyenne d'un estimateur T_n de θ est noté $\mathbb{EQM}(T_n)$ et on a :

$$\mathbb{EQM}(T_n) = \mathbb{V}(T_n) + \mathcal{B}(T_n, \theta)$$

Le meilleur estimateur possible de θ est un estimateur **sans biais** et de **variance minimal**.